

NodeWaste: Smart Waste Scan, Play & Track System

1. Mengumpulkan dan menganalisis berbagai permasalahan, kemudian menentukan satu solusi utama yang akan dikembangkan dalam proyek

Berdasarkan hasil analisis, kami menemukan beberapa permasalahan terkait pengelolaan sampah di masyarakat. Masih banyak orang yang belum memahami cara memilah sampah dengan benar, seperti membedakan sampah organik, anorganik, dan B3. Selain itu, kurangnya edukasi mengenai pengolahan dan pemanfaatan sampah membuat volume sampah terus meningkat dan berdampak buruk bagi lingkungan.

Dari permasalahan tersebut, tim menentukan satu solusi utama yaitu mengembangkan aplikasi berbasis web bernama NodeWaste: Smart Waste Scan, Play & Track System. Aplikasi ini menggunakan teknologi Artificial Intelligence untuk membantu pengguna mengenali jenis sampah melalui gambar, sekaligus memberikan rekomendasi pengelolaan sampah yang tepat.

Dengan adanya aplikasi ini, diharapkan masyarakat dapat lebih mudah memahami pengelolaan sampah dan lebih sadar terhadap pentingnya sustainable living.

2. Mendefinisikan pertanyaan bisnis yang dapat diukur

- Seberapa baik performa model dalam mengklasifikasikan jenis sampah berdasarkan citra?
- Kategori sampah apa yang paling sulit diklasifikasikan dan apa penyebabnya?
- Bagaimana penerapan model ini dapat meningkatkan efisiensi dan akurasi dalam proses pemilahan sampah?

3. Import Library

- Insight
Tahap ini menyiapkan seluruh library yang dibutuhkan untuk proses data wrangling, EDA, preprocessing gambar, training EfficientNetB0, evaluasi model, A/B Testing, dan export laporan PDF.
- Library utama yang digunakan:
 - PIL untuk membaca dan memvalidasi gambar.
 - hashlib untuk mendeteksi gambar duplikat.
 - Split folders untuk membagi dataset menjadi train, validation, dan test.
 - TensorFlow/Keras untuk membangun model EfficientNetB0. sklearn untuk evaluasi dan class weight. fpdf2 untuk membuat laporan PDF.

4. Melakukan proses Data Wrangling secara end-to-end

Dalam tahap Data Wrangling, tim melakukan proses pengumpulan dan evaluasi data secara end-to-end menggunakan dataset citra sampah yang diperoleh dari sumber publik seperti Kaggle dan open dataset lainnya yang relevan dengan klasifikasi jenis sampah. Dataset yang digunakan terdiri dari berbagai gambar sampah seperti organik,

anorganik, dan residu yang nantinya akan digunakan untuk proses pelatihan model klasifikasi.

Berikut link dataset nya :

- <https://www.kaggle.com/datasets/alistairking/recyclable-and-household-waste-classification>
- <https://www.kaggle.com/datasets/kingabzpro/singapore-waste-management>

Berikut hasil lengkapnya (yang berbentuk table ada disini) :

- https://drive.google.com/drive/folders/1jIKWV12E6Jw1ZUbcIJPXkOdArRi_KmbU

A. Gathering Data: Mengumpulkan data atau mencari dataset yang relevan, baik dari sumber publik maupun melalui proses scraping

- Insight

Tahap gathering data digunakan untuk membaca dataset awal yang masih mentah sebelum dibersihkan. Untuk image classification menggunakan flow_from_directory, dataset harus memiliki struktur folder berdasarkan kelas.

Class/Label		
aerosol cans	glass beverage bottles	plastic shopping bags
aluminum food cans	glass cosmetic containers	plastic soda bottles
aluminum soda cans	glass food jars	plastic straws
cardboard boxes	magazines	plastic trash bags
cardboard packaging	newspaper	plastic water bottles
clothing	office paper	shoes
coffee grounds	paper cups	steel food cans
disposable plastic cutlery	plastic cup lids	styrofoam cups
eggshells	plastic detergent bottles	styrofoam food containers
food waste	plastic food containers	tea bags

B. Assessing Data: Mengevaluasi kualitas dan struktur data

- Insight

Assessing data bertujuan untuk mengevaluasi kualitas dataset sebelum dibersihkan. Pada dataset gambar, masalah yang umum ditemukan adalah :

- gambar rusak/corrupt
- gambar duplikat
- ukuran file terlalu kecil
- resolusi gambar tidak konsisten
- distribusi kelas tidak seimbang

filename	label	extension	file_size_kb
Image_133.png	aerosol cans	.png	24.4
Image_136.png	aerosol cans	.png	52.9
Image_103.png	aerosol cans	.png	54.71
Image_110.png	aerosol cans	.png	59
Image_10.png	aerosol cans	.png	77.43

label	jumlah_gambar	percentage
clothing	498	3.35

newspaper	498	3.35
cardboard packaging	497	3.35
aluminum soda cans	497	3.35
food waste	497	3.35

filename	is_corrupt	width	height	mode
Image_133.png	False	256	256	RGB
Image_136.png	False	256	256	RGB
Image_103.png	False	256	256	RGB
Image_110.png	False	256	256	RGB
Image_10.png	False	256	256	RGB

Jumlah yang terindikasi duplicate : 3676

C. Cleaning Data: Membersihkan dan mempersiapkan data sebelum masuk ke tahap analisis.

Cleaning data dilakukan untuk menghasilkan dataset final yang valid dan siap digunakan untuk EDA, split dataset, dan modeling.

Proses Cleaning :

- menghapus gambar corrupt
- menghapus duplicate image berdasarkan hash
- mengubah gambar ke format RGB
- menyimpan gambar bersih ke folder baru
- menyimpan laporan hasil cleaning.

Insight

- Cleaning sangat penting karena gambar duplikat dapat membuat model terlihat memiliki akurasi tinggi, tetapi sebenarnya hanya menghafal gambar yang sama.

Jumlah gambar sebelum cleaning	14856
Jumlah gambar setelah cleaning	11180
Jumlah gambar corrupt	0
Jumlah duplicate image	3676
Jumlah nama file tidak valid	0
Jumlah gagal cleaning	0

5. Melakukan Exploratory Data Analysis (EDA) untuk mendapatkan insight dari data

EDA dilakukan untuk memahami kondisi dataset setelah cleaning.

Analisis yang Dilakukan



- Aspect ratio.
- Brightness atau tingkat kecerahan.
- Contrast atau variasi intensitas piksel.
- Sharpness untuk mendeteksi gambar blur.
- Edge density untuk melihat kepadatan tepi objek.
- Rata-rata warna RGB.

Insight

- Kualitas citra sangat berpengaruh terhadap performa model EfficientNetB0. Gambar yang blur, terlalu gelap, terlalu terang, atau memiliki objek yang kurang jelas dapat membuat model sulit mengenali pola visual.

filename	aspect ratio	brightness	contrast	sharpness	edge density
Image_49.png	1.0	248.642075	22.905932	1073.517076	0.023849
Image_247.png	1.0	145.380020	111.222513	1108.062973	0.027115
Image_153.png	1.0	233.394409	45.331397	563.065338	0.051239
Image_93.png	1.0	241.253571	37.813166	1771.517395	0.056305
Image_99.png	1.0	202.635574	54.943725	875.909134	0.046402

label	aspect_ratio	brightness	contrast	sharpness	edge_density
aerosol_cans	1.0	177.83	72.25	2119.45	0.08
aluminum_food_cans	1.0	199.61	59.28	1934.90	0.09
aluminum_soda_cans	1.0	190.49	61.30	1615.45	0.08
cardboard_boxes	1.0	192.66	61.72	1771.517395	0.05
cardboard_packaging	1.0	196.73	58.27	1060.00	0.06



Insight Citra :

- Total gambar dianalisis : 11180
- Jumlah gambar blur : 395
- Jumlah gambar terlalu gelap : 54
- Jumlah gambar terlalu terang : 2574

Kelas dengan rata-rata sharpness terendah : plastic_detergent_bottles

Kelas dengan rata-rata brightness terendah : coffee_grounds

Kelas dengan rata-rata brightness tertinggi : glass_beverage_bottles

6. Data Dictionary

Data dictionary menjelaskan variabel yang digunakan dalam pipeline project. Karena dataset berbentuk gambar, data dictionary tidak hanya menjelaskan kolom dataset, tetapi juga variabel preprocessing, generator, prediksi, dan metrik evaluasi.

- Insight

Data dictionary digunakan untuk menjelaskan variabel, fitur, dan informasi yang digunakan dalam proses klasifikasi sampah berbasis citra.

Kategori	Nama Variabel	Tipe Data	Deskripsi
Input Data	image	Image/File	Gambar sampah sebagai input utama model.
Input Data	filename	String	Nama file gambar.
Input Data	path	String	Lokasi file gambar.
Input Data	label	Categorical	Kategori atau kelas sampah.
Input Data	class_names	List	Daftar seluruh nama kelas sampah.
Preprocessing	IMG_HEIGHT	Integer	Tinggi gambar setelah preprocessing.
Preprocessing	IMG_WIDTH	Integer	Lebar gambar setelah preprocessing.

7. Split Dataset

Dataset dibagi menjadi train, validation, dan test.

Rasio Split

- Train: 70%
- Validation: 15%
- Test: 15%

Insight

Split dilakukan sebelum feature engineering dan modeling untuk mencegah data leakage.


Label	Jumlah Gambar	Split
aerosol_cans	170	train
aluminum_food_cans	172	train
aluminum_soda_cans	169	train
cardboard_boxes	175	train
cardboard_packaging	143	train
shoes	38	test
steel_food_cans	30	test
styrofoam_cups	37	test
styrofoam_food_containers	37	test
tea_bags	38	test

8. Feature Engineering

Feature engineering pada image classification dilakukan melalui preprocessing dan transformasi citra.

- Insight
Augmentasi hanya dilakukan pada data training agar model lebih general dan tidak menghafal data.

Class Weight	
aerosol cans	0.9925
aluminum food cans	0.9810
aluminum soda cans	0.9984
cardboard boxes	0.9642
cardboard packaging	1.1800
clothing	0.9642
coffee grounds	0.9810
disposable plastic cutlery	0.9810
eggshells	0.9642
food waste	0.9984
glass beverage bottles	1.0044
glass cosmetic containers	0.9810
glass food jars	0.9984
magazines	0.9810
newspaper	0.9697
office paper	0.9697
paper cups	0.9810
plastic cup lids	1.0226
plastic detergent bottles	0.9810
plastic food containers	0.9984
plastic shopping bags	0.9810
plastic soda bottles	1.0044
plastic straws	0.9810
plastic trash bags	1.0044
plastic water bottles	1.0226
shoes	0.9642
steel food cans	1.2687
styrofoam cups	0.9984
styrofoam food containers	0.9984
tea bags	0.9810



9. Data Leakage

Data leakage terjadi ketika informasi dari data validation/test masuk ke proses training. Pencegahan

- Split dilakukan sebelum training.
- Augmentasi hanya pada training.
- Validation dan test tidak diaugmentasi.
- Test generator tidak diacak.
- Test hanya digunakan pada evaluasi akhir.

Insight

Pencegahan leakage membuat hasil evaluasi lebih valid dan tidak menipu.

Aspek Pencegahan Leakage	Status	Keterangan
Split dataset sebelum training	Aman	Dataset dibagi sebelum masuk model.
Train/validation/test terpisah	Aman	Setiap subset berada pada folder berbeda.
Augmentasi hanya pada training	Aman	Hanya train_datagen yang memakai augmentasi.
Validation dan test tanpa augmentasi	Aman	val_test_datagen tidak memakai augmentasi.
Test generator shuffle = False	Aman	Urutan test stabil untuk evaluasi.
Class weight dari train saja	Aman	Menghindari informasi validation/test masuk training
Test tidak dipakai untuk training	Aman	Test hanya dipakai setelah model selesai dilatih.

10. Modeling EfficientNetB0 & Evaluasi Model

Model menggunakan EfficientNetB0 dengan transfer learning.

Arsitektur

- EfficientNetB0 sebagai feature extractor.
- BatchNormalization untuk stabilisasi fitur.
- Dense layer untuk klasifikasi.
- Keras sebagai membangun dan melatih model deep learning.
- Softmax untuk klasifikasi multiclass.

Insight

EfficientNetB0 lebih ringan dibanding RestNet50 sehingga lebih cocok untuk Colab, deployment, dan eksperimen cepat.

```
Final Training Accuracy: 96.53%
Final Validation Accuracy: 93.11%
Final Training MAE: 0.0064
Final Validation MAE: 0.0091
Test Accuracy : 93.33%
Test MAE      : 0.0083
Test Loss     : 0.2214
```

11. Visualisasi


Visualisasi digunakan untuk membaca performa model secara lebih jelas.



Visualisasi yang Digunakan

- Grafik accuracy.
- Grafik loss.
- Confusion matrix.
- Performa per kategori

Insight

Visualisasi membantu menunjukkan gambaran performa yang ingin di capai.






12. Explanatory Analysis Pertanyaan Bisnis

Insight :

Berdasarkan hasil EDA, evaluasi model, dan explanatory analysis, model EfficientNet pada proyek NodeWaste menunjukkan performa yang cukup baik dalam klasifikasi citra sampah. Namun, beberapa kategori masih sulit dibedakan akibat kemiripan visual, kualitas gambar, dan class imbalance. Implementasi sistem ini memiliki potensi besar untuk meningkatkan efisiensi, konsistensi, dan akurasi proses pemilahan sampah berbasis Artificial Intelligence.

A. Seberapa baik performa model dalam mengklasifikasikan jenis sampah berdasarkan citra?


Metric	Score
Accuracy	0,9333
Precision	0,9325
Recall	0,9318
F1-Score	0,9321




B. Kategori sampah apa yang paling sulit diklasifikasikan dan apa penyebabnya?

Kategori Sampah	Total Data	Prediksi Benar	Prediksi Salah	Error Rate
aluminum food cans	38	15	23	0.605263
steel food cans	30	12	18	0.600000
cardboard packaging	32	13	19	0.593750
glass beverage bottles	37	26	11	0.297297
plastic water bottles	37	26	11	0.297297
cardboard boxes	38	27	11	0.289474
plastic cup lids	37	27	10	0.270270
tea bags	38	29	9	0.236842
plastic soda bottles	36	28	8	0.222222
magazines	38	30	8	0.210526
plastic trash bags	36	29	7	0.194444
aluminum soda cans	37	30	7	0.189189
newspaper	38	31	7	0.184211
office paper	38	31	7	0.184211
paper cups	38	31	7	0.184211
food waste	37	31	6	0.162162
aerosol cans	37	31	6	0.162162
glass cosmetic containers	38	31	6	0.157895
plastic food containers	37	32	5	0.135135
styrofoam cups	37	32	5	0.135135
disposable plastic cutlery	38	33	5	0.131579
plastic shopping bags	38	33	5	0.131579
plastic detergent bottles	38	34	4	0.105263
clothing	38	34	4	0.105263

glass food jars	37	34	3	0.081081
styrofoam food containers	37	34	3	0.081081
coffee grounds	38	36	2	0.052632
eggshells	38	36	2	0.052632
shoes	38	37	1	0.026316
plastic straws	38	37	1	0.026316



C. Bagaimana penerapan model ini dapat meningkatkan efisiensi dan akurasi dalam proses pemilahan sampah?



Ringkasan Insight Bisnis

1. Performa Model :

- model memperoleh accuracy sebesar 93.33%
- precision sebesar 93.25%
- recall sebesar 93.18%
- dan F1-score sebesar 93.21%

Hal ini menunjukkan bahwa model mampu mengklasifikasikan jenis sampah berdasarkan citra.

2. Kategori Paling sulit :

Kategori yang paling sulit diklasifikasikan Adalah aluminum_food_cans dengan error rate sebesar 60.53%.

Kemungkinan penyebabnya adalah kemiripan bentuk objek, warna yang serupa, background gambar yang tidak konsisten, dan perbedaan pencahayaan.

3. Penerapan model untuk efisiensi dan akurasi :


Dengan tingkat akurasi testing mencapai **93.33%**, sistem mampu mengenali jenis sampah secara cepat dan konsisten sehingga dapat:

- Mengurangi kesalahan pemilahan sampah oleh manusia.
- Mempercepat proses sortir sampah pada fasilitas pengolahan.
- Mengurangi biaya operasional tenaga kerja.
- Mendukung proses daur ulang yang lebih efektif.
- Membantu meningkatkan kebersihan dan pengelolaan lingkungan.

Visualisasi accuracy dan MAE menunjukkan bahwa model memiliki performa stabil dengan error rendah, sehingga layak diterapkan pada sistem smart waste management berbasis AI.


13. A/B Testing

Validation Accuracy




Pada tahap validasi, model EfficientNetB0 memperoleh akurasi sebesar **93.11%**, lebih tinggi dibandingkan ResNet50 yang mencapai **91.78%**. Hasil ini menunjukkan bahwa EfficientNetB0 memiliki kemampuan generalisasi yang lebih baik terhadap data validasi dan mampu mempelajari pola citra sampah dengan lebih efektif. Selisih performa sekitar 2.66% mengindikasikan bahwa arsitektur EfficientNetB0 lebih optimal dalam mengekstraksi fitur penting pada dataset klasifikasi sampah.

Training Accuracy




Pada data training, EfficientNetB0 memperoleh akurasi sebesar **96.53%**, sedangkan ResNet50 mencapai **95.58%**. Nilai ini menunjukkan bahwa kedua model mampu mempelajari pola data dengan sangat baik, namun EfficientNetB0 memiliki kemampuan pembelajaran yang lebih tinggi. Tingginya training accuracy juga mengindikasikan bahwa model berhasil mengenali karakteristik setiap kategori sampah selama proses pelatihan.

Validation MAE




Nilai Validation MAE pada EfficientNetB0 sebesar **0.0091**, lebih rendah dibandingkan ResNet50 yaitu **0.0129**. Semakin kecil nilai MAE menunjukkan bahwa kesalahan prediksi model semakin rendah. Hal ini membuktikan bahwa EfficientNetB0 menghasilkan prediksi yang lebih konsisten dan lebih akurat pada data validasi dibandingkan ResNet50.

Training MAE




Pada tahap training, EfficientNetB0 memperoleh nilai MAE sebesar **0.0064**, sedangkan ResNet50 sebesar **0.0102**. Perbedaan ini menunjukkan bahwa EfficientNetB0 memiliki tingkat error pelatihan yang jauh lebih kecil. Dengan demikian, model EfficientNetB0 lebih efektif dalam menyesuaikan parameter pembelajaran untuk mengenali pola citra sampah.

Test MAE



Pada data pengujian, EfficientNetB0 kembali menunjukkan performa terbaik dengan nilai MAE sebesar **0.0086**, lebih rendah dibandingkan ResNet50 sebesar **0.0113**. Hasil ini menunjukkan bahwa EfficientNetB0 memiliki kemampuan prediksi yang lebih stabil pada data baru yang belum pernah dilihat sebelumnya. Rendahnya error pada data test juga mengindikasikan bahwa model memiliki generalisasi yang baik dan tidak mengalami overfitting berlebihan.

Test Accuracy



Pada tahap pengujian akhir, EfficientNetB0 memperoleh akurasi sebesar **93.33%**, sedangkan ResNet50 mencapai **92.89%**. Hasil ini membuktikan bahwa EfficientNetB0 menjadi model terbaik dalam klasifikasi citra sampah karena mampu memberikan performa paling tinggi pada data testing. Tingginya test accuracy menunjukkan bahwa model dapat diterapkan secara efektif untuk membantu proses pemilahan sampah otomatis dengan tingkat akurasi yang tinggi.

Berdasarkan seluruh hasil perbandingan, model EfficientNetB0 secara konsisten menunjukkan performa yang lebih unggul dibandingkan ResNet50 pada seluruh metrik evaluasi, baik accuracy maupun MAE. EfficientNetB0 mampu menghasilkan akurasi lebih tinggi serta error yang lebih rendah pada data training, validation, maupun testing. Oleh karena itu, EfficientNetB0 dapat dianggap sebagai model yang paling optimal dan paling stabil untuk implementasi sistem klasifikasi sampah berbasis deep learning.